

Hafta 06 - Destek Vektör Makinesi

BGM 565 - Siber Güvenlik için Makine Öğrenme Yöntemleri

Bilgi Güvenliği Mühendisliği
Yüksek Lisans Programı

Dr. Ferhat Özgür Çatak
ozgur.catak@tubitak.gov.tr

İstanbul Şehir Üniversitesi
2018 - Bahar

İçindekiler

- 1 Destek Vektör Makinesi
 - Giriş
 - Doğrusal Ayrıştırılabilir Durum
 - Margin
 - Karar Sınırlarının Uzaklığı
 - Optimizasyon Problemi
 - Lagrange Fonksiyonu
- 2 Yumuşak Marjin Hiperdüzlem
 - Giriş
 - Hinge Loss
 - Soft Margin SVM
- 3 Doğrusal Olmayan Karar Sınırı
 - Giriş
 - Çekirdek

Destek Vektör Makinesi

Support Vector Machine

Destek Vektör Makinesi

- ▶ Destek Vektör Makinesi (Support Vector Machine - SVM), en iyi denetimli öğrenme algoritması
- ▶ Ayrılabilir durumda **büyük marjlı bir sınıflandırıcı** (large-margin classifier) tanımlanması
- ▶ Doğrusal olmayan durumlarda **yumuşak kenarlı SVM** (soft-margin SVM) uygulamak için **çekirdek hilesi** (kernel-trick) kullanılır.

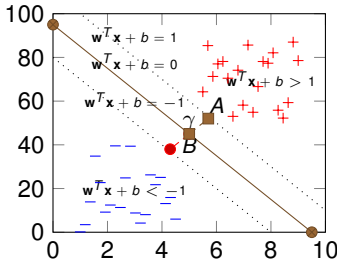
The linearly separable case

Marjın

Margin of a linear classifier

Tanım

- ▶ $\mathcal{D} = \{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)}) | \mathbf{x}^{(i)} \in \mathbb{R}^n, y^{(i)} \in \{-1, +1\}\}$
- ▶ **Fonksiyonel marjın** (Functional margin) $\gamma^{(i)} = y^{(i)}(\mathbf{w}^T \mathbf{x} + b)$ ve $y^{(i)}(\mathbf{w}^T \mathbf{x} + b) > 0$
 - ▶ Eğer $y^{(i)} = +1$, Fonk. marjın'ın güvenilir olması için $(\mathbf{w}^T \mathbf{x} + b)$ ifadesi **büyük bir pozitif sayı** olmalı
 - ▶ Eğer $y^{(i)} = -1$, Fonk. marjın'ın güvenilir olması için $(\mathbf{w}^T \mathbf{x} + b)$ ifadesi **büyük bir negatif sayı** olmalı



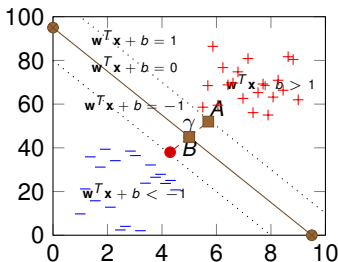
Karar Fonksiyonu ve Karar Sınırı

- ▶ Karar fonksiyonu (decision function)

$$h(\mathbf{x}) = \text{sign}(\mathbf{w}^T \mathbf{x} + b)$$
 - ▶ $\mathbf{w}^T \mathbf{x} + b > 0 \Rightarrow y_i = +1$
 - ▶ $\mathbf{w}^T \mathbf{x} + b < 0 \Rightarrow y_i = -1$

Margin of a linear classifier

- $\mathcal{D} = \{(\mathbf{x}^{(1)}, y^{(1)}), \dots, (\mathbf{x}^{(m)}, y^{(m)}) | \mathbf{x}^{(i)} \in \mathbb{R}^n, y^{(i)} \in \{-1, +1\}\}$
- **Fonksiyonel marjın** (Functional margin) $\gamma^{(i)} = y^{(i)}(\mathbf{w}^T \mathbf{x} + b)$ ve $y^{(i)}(\mathbf{w}^T \mathbf{x} + b) > 0$
 - Eğer $y^{(i)} = +1$, Fonk. marjın'ın güvenilir olması için $(\mathbf{w}^T \mathbf{x} + b)$ ifadesi **büyük bir pozitif sayı** olmalı
 - Eğer $y^{(i)} = -1$, Fonk. marjın'ın güvenilir olması için $(\mathbf{w}^T \mathbf{x} + b)$ ifadesi **büyük bir negatif sayı** olmalı



- ▶ Eğitim kümesi doğrusal ayrıştırılabilir (linearly separable) ise, aralarında uzaklık en fazla olacak şekilde birbirine paralel iki hiperdüzlem (hyperplane) seçebiliriz.
- ▶ İki hiperdüzlem arasında bulunan bölge: **margin**
 - ▶ $\mathbf{w}^T \mathbf{x} + b = +1$
 - ▶ $\mathbf{w}^T \mathbf{x} + b = -1$

Karar Sınırlarının Uzaklığı I

Hiperdüzlem uzaklığı


- Bir noktanın, (x_0, y_0) , bir doğruya, $Ax + By + c = 0$, olan uzaklığı

$$\frac{|Ax_0 + By_0 + c|}{\sqrt{A^2 + B^2}}$$

- H_0 ve H_1 arasında uzaklık $\frac{|\mathbf{w}^T \mathbf{x} + b|}{\|\mathbf{w}\|} = \frac{1}{\|\mathbf{w}\|}$

- Bu durumda H_1 ve H_2 arasında uzaklık: $\frac{2}{\|\mathbf{w}\|}$

Karar Sınırlarının Uzaklığı II



Karar Sınırlarının Uzaklığı III

Optimizasyon

- ▶ **Marjin maksimizasyonu** için $\|\mathbf{w}\|$ minimize edilmesi gerekmektedir.
- ▶ H_1 ve H_2 arasında veri olmadığı kabul edersek

$$\mathbf{w} \cdot \mathbf{x} + b \geq +1 \text{ if } y_i = +1 \quad (1)$$

$$\mathbf{w} \cdot \mathbf{x} + b \leq -1 \text{ if } y_i = -1$$

$$y_i(\mathbf{w} \cdot \mathbf{x} + b) \geq +1 \quad \forall \mathbf{x}_i \quad (2)$$

Optimizasyon Problemi I

Optimizasyon Problemi


- Optimizasyon problemini değiştirelim. Yeni *quadratic optimizasyon* problemi

$$\begin{aligned} \arg \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} : y^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1, i = 1, \dots, m \end{aligned} \quad (3)$$

- **Hedef:** *convex quadratic*
 - Yüzey paraboloid, Tek çözüm mevcut.
- **Kısıtlar:** *linear*.
- **Çözüm:** *Lagrangian multipler method*

Optimizasyon Problemi II

Elliptic Paraboloid $z = \frac{x^2}{a^2} + \frac{y^2}{b^2}$



Lagrange Fonksiyonu I

Lagrange multiplier

Bir fonksiyonun, $f(x, y, \dots)$, eşitlik kısıtlarına, $g(x, y, \dots) = c$, bağlı olarak local maxima ve minima noktalarının bulunması için bir stratejidir.

Örnek optimizasyon problemi:

$$\begin{aligned} \min_{x,y} f(\mathbf{w}) \\ \text{subject to } h(\mathbf{w}) = 0 \end{aligned}$$

Adım 1 Yeni değişken λ ve yeni fonksiyon \mathcal{L} olmak üzere *Lagrange Fonksiyonu*

$$\mathcal{L}(\mathbf{w}, \beta) = f(\mathbf{w}) + \sum_{i=1}^I \beta_i h_i(\mathbf{w}) \quad (4)$$

► β_i değerleri *Lagrange çarpanlarıdır*.

Lagrange Fonksiyonu II

- \mathbf{w} ve β değerlerini çözebilmek için \mathcal{L} 'nin kısmi türevlerini alıp 0'a eşitlenmelidir.

$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}_i} = 0; \frac{\partial \mathcal{L}}{\partial \beta_i} = 0 \quad (5)$$

- Dual form optimizasyon problemi

$$\max_{\alpha} \min_{\mathbf{w}} \mathcal{L}(\mathbf{w}, \alpha) \quad (6)$$

Lagrange Fonksiyonu - Örnek I

Lokal mimimum ve maksimum değerlerinin bulunması

$$f(x, y) = xy \text{ ve Eğri } 3x^2 + y^2 = 6$$

Çözüm

$$\nabla f = \langle y, x \rangle \text{ ve } g(x, y) = \langle 6x, 2y \rangle.$$

$$y = 6\alpha x, \quad x = 2\alpha y,$$

$$3x^2 + y^2 = 6$$

1. ve 2. eşitlik birleştirilirse

$$y = 6\alpha(2\alpha y) = 12\alpha^2 y \Rightarrow 12\alpha^2 = 1$$



. Bu sonucu $3x^2 + y^2 = 6$ ifadesinde yerine koyarsak;

$$\begin{aligned} 6 &= 3x^2 + (6\alpha x)^2 \\ &= 3x^2 + 36\alpha^2 x^2 \\ &= 3x^2 + 3(12\alpha^2)x^2 \\ &= 3x^2 + 3x^2 \end{aligned}$$

sonuç: $x = \pm 1$ ve $y = \pm\sqrt{3}$: Kritik noktalar:

$$(1, \sqrt{3}), (1, -\sqrt{3}), (-1, \sqrt{3}), (-1, -\sqrt{3}),$$

Lagrange Fonksiyonu - Örnek II



SVM - Lagrange Fonksiyonu I

Destek Vektör Makinesi

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad (7)$$

$$s.t. y^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1, i = 1, \dots, m$$

Kısıt fonksiyonu yeni form

$$g_i(\mathbf{w}) = -y^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) + 1 \leq 0$$

SVM - Lagrange Fonksiyonu II

SVM optimizasyon probleminin Lagrange fonksiyonu

$$\mathcal{L}(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i \left[y^{(i)} (\mathbf{w}^T \mathbf{x}^{(i)} + b) - 1 \right] \quad (8)$$

\mathcal{L} fonksiyonunun \mathbf{w} 'ye göre türevi

$$\frac{\partial}{\partial \mathbf{w}} \mathcal{L}(\mathbf{w}, b, \alpha) = \mathbf{w} - \sum_{i=1}^m \alpha_i y^{(i)} \mathbf{x}^{(i)} = \mathbf{0} \Rightarrow \mathbf{w} = \sum_{i=1}^m \alpha_i y^{(i)} \mathbf{x}^{(i)} \quad (9)$$

Bu durumda

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y^{(i)} \mathbf{x}^{(i)} \quad (10)$$

\mathcal{L} fonksiyonunun b 'ye göre türevi

$$\frac{\partial}{\partial b} \mathcal{L}(\mathbf{w}, b, \alpha) = \sum_{i=1}^m \alpha_i y^{(i)} = 0 \quad (11)$$

Lagrange fonksiyonuna bu sonuçları birleştirirsek

SVM - Lagrange Fonksiyonu III

$$\begin{aligned}\mathcal{L} &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m y^{(i)} y^{(j)} \alpha_i \alpha_j \left(\mathbf{x}^{(i)} \right)^T \mathbf{x}^{(j)} - b \sum_{i=1}^m \alpha_i y^{(i)} \\ \mathcal{L} &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m \left[y^{(i)} y^{(j)} \alpha_i \alpha_j \left(\left(\mathbf{x}^{(i)} \right)^T \mathbf{x}^{(j)} \right) \right]\end{aligned}\tag{12}$$

Optimizasyon problemi

$$\begin{aligned}\max_{\alpha} W(\alpha) &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m \left[y^{(i)} y^{(j)} \alpha_i \alpha_j \left(\left(\mathbf{x}^{(i)} \right)^T \mathbf{x}^{(j)} \right) \right] \\ \text{s.t. } \alpha_i &\geq 0, i = 1, \dots, m \\ \sum_{i=1}^m \alpha_i y^{(i)} &= 0\end{aligned}\tag{13}$$

Python

Python

```
class sklearn.svm.SVC(C=1.0, kernel='rbf', degree=3, gamma=0.0,  
coef0=0.0, shrinking=True, probability=False, tol=0.001, cache_size=200,  
class_weight=None, verbose=False, max_iter=-1, random_state=None)
```

Lab

Lab - 1

İçindekiler



- 1 Destek Vektör Makinesi
 - Giriş
 - Doğrusal Ayrıştırılabilir Durum
 - Margin
 - Karar Sınırlarının Uzaklığı
 - Optimizasyon Problemi
 - Lagrange Fonksiyonu
- 2 Yumuşak Marjin Hiperdüzlem
 - Giriş
 - Hinge Loss
 - Soft Margin SVM
- 3 Doğrusal Olmayan Karar Sınırı
 - Giriş
 - Çekirdek

Yumuşak Marjın Hiperdüzlem I

Soft Margin Hyperplane

Doğrusal Ayrıştırılmama Durumu

- ▶ Eğer veri kümemiz doğrusal ayrıştırılabilir değilse, *Hard Margin SVM* algoritması uygun olmayacaktır.
- ▶ Veya outliers olması durumunda hassasiyetin azaltılması gerekebilir.
- ▶ Bu durumu çözmek için, bir sınıfa ait bir örneği sınırın diğer tarafında yer almasına izin verilebilir.



Yumuşak Marjin Hiperdüzlem II

Soft Margin Hyperplane

Çözüm: Slack Variables

$$\begin{aligned} \min_{\mathbf{w}} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \epsilon_i \\ \text{s.t.} \quad & y^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1 - \epsilon_i, \quad i = 1, \dots, m \\ & \epsilon_i \geq 0, \quad i = 1, \dots, m \end{aligned} \quad (14)$$

Yeni Lagrange fonksiyonu

$$\mathcal{L} = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^m \epsilon_i - \sum_{i=1}^m \alpha_i \left[y^{(i)}(\mathbf{x}^T \mathbf{w} + b) - 1 + \epsilon_i \right] - \sum_{i=1}^m r_i \epsilon_i \quad (15)$$

α_i ve r_i ifadeleri Lagrange çarpanlarıdır (kısıtları ≥ 0)

Yumuşak Marjin Hiperdüzlem III

Soft Margin Hyperplane

Optimizasyon problemi

$$\begin{aligned} \max_{\alpha} W(\alpha) &= \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m \left[y^{(i)} y^{(j)} \alpha_i \alpha_j \left((\mathbf{x}^{(i)})^T \mathbf{x}^{(j)} \right) \right] \\ \text{s.t. } \alpha_i &\geq 0 \geq C, i = 1, \dots, m \\ \sum_{i=1}^m \alpha_i y^{(i)} &= 0 \end{aligned} \quad (16)$$

Hard Margin vs Soft Margin


- ▶ Hard margin: $0 \leq \alpha_i$
- ▶ Soft margin: $0 \leq \alpha_i \leq C$
- ▶ C
 - ▶ Yüksek C : hata sayısı az, dar margin
 - ▶ Düşük C : hata sayısı çok, geniş margin

Hinge Loss

Hinge Loss

- Amaç: bütün örnekler için $y^{(i)} h(\mathbf{x}^{(i)}) \geq 1$
- Hinge loss fonksiyonu

$$\begin{aligned} \ell_{\text{hinge}}(u, y) &= \max(1 - uy, 0) \\ &= \begin{cases} 0, & \text{if } yu \geq 1 \\ 1 - yu, & \text{otherwise} \end{cases} \end{aligned} \quad (17)$$



Soft Margin SVM

Soft Margin SVM

- **Large margin** ve **hataların** optimizasyonu.

$$\min_{\mathbf{w}, b} \left(\frac{1}{2} \|\mathbf{w}\|^2 + C \times \text{error}(h) \right)$$

- **error:**

$$\begin{cases} 0, & \text{if } y(\mathbf{w}^T \mathbf{x} + b) \geq 1 \\ 1 - y(\mathbf{w}^T \mathbf{x} + b) & \text{otherwise} \end{cases}$$

- **Soft-margin SVM**

$$\operatorname{argmin}_{\mathbf{w}, b} \left(\frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max \left(0, 1 - y^{(i)}(\mathbf{w}^T \mathbf{x} + b) \right) \right)$$

Lab - 2

Lab-2

İçindekiler


- 1 Destek Vektör Makinesi
 - Giriş
 - Doğrusal Ayrıştırılabilir Durum
 - Margin
 - Karar Sınırlarının Uzaklığı
 - Optimizasyon Problemi
 - Lagrange Fonksiyonu
- 2 Yumuşak Marjin Hiperdüzlem
 - Giriş
 - Hinge Loss
 - Soft Margin SVM
- 3 Doğrusal Olmayan Karar Sınırı
 - Giriş
 - Çekirdek

Doğrusal Olmayan Karar Sınırı

Nonlinear decision boundary


Doğrusal Olmayan Karar Sınırı

- Veri kümesi içinde yer alan örnekler, \mathbf{x}_i , daha yüksek boyutlu nitelik uzayına (Feature Space) haritalanarak doğrusal ayrıştırılabilir hale getirilebilir.
- \mathbf{x}_i örnekleri $\phi(\mathbf{x}_i)$ kullanılarak yüksek boyutlu uzay haritalaması (higher-dimensional space mapping).




Bir özellik alanına doğrusal olmayan eşleme I

Non-linear mapping to a feature space



Bir özellik alanına doğrusal olmayan eşleme II

Non-linear mapping to a feature space




Şekil: polar coordinates

Bir özellik alanına doğrusal olmayan eşleme III

Non-linear mapping to a feature space

$$\Phi : \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \rightarrow \begin{pmatrix} x_1^2 \\ x_2^2 \\ \sqrt{2}x_1x_2 \end{pmatrix} \quad \mathbb{R}^2 \rightarrow \mathbb{R}^3$$



Çekirdek Fonksiyonları I

Kernel Functions

Çekirdek Hilesi

- ▶ Yüksek boyutlu veri kümelerinde $\phi(\mathbf{x}_i)^T \mathbf{x}_i$ hesaplanması zorlu olabilir.
- ▶ Bunun yerine bir çekirdek fonksiyonu kullanılarak ϕ nitelik haritalaması tanımlanabilir.

$$K(x, z) = \phi(x)^T \phi(z)$$

- ▶ $K(x, z)$ hesaplaması $\phi(x)$ hesaplamasına göre daha kolay olabilir.

Karar Sınırı

$$\mathbf{w}^T \phi(\mathbf{x}) - b = 0 \quad (18)$$

Çekirdek Fonksiyonları II

Kernel Functions

SVM in the feature space

$$\begin{aligned} \max_{\alpha \geq 0} & \left(\sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) \right) \\ \max_{\alpha \geq 0} & \left(\sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j) \right) \end{aligned} \quad (19)$$

Doğrusal Olmayan SVM Çekirdek Fonksiyonları

- Polynomial: $K(\mathbf{x}, \mathbf{y}) = (\mathbf{x} \cdot \mathbf{y} + 1)^p$
- Radial basis function: $K(\mathbf{x}, \mathbf{y}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{y}\|^2}{2\sigma^2}\right)$
- Sigmoid: $K(\mathbf{x}, \mathbf{y}) = \tanh(\mathbf{x} \cdot \mathbf{y} - s)$

Lab

Lab-3