Hafta 07 - Sinir Ağları

BGM 565 - Siber Güvenlik için Makine Öğrenme Yöntemleri

Bilgi Güvenliği Mühendisliği
Yüksek Lisans Programı

Dr. Ferhat Özgür Çatak
ozgur.catak@tubitak.gov.tr

İstanbul Şehir Üniversitesi
2018 - Bahar

İçindekiler

İçindekiler

Tek-Girişli Sinir
Single-Input Neuron

Single-Input Neuron

- Girdi $p \in \mathbb{R}$, bir ağırlık $w \in \mathbb{R}$ ile çarpılarak wp formatına dönüştürülür.
- Başka bir girdi 1, *bias* b ile çarpılarak bir toplayıcıya verilir.
- Bu toplam n bir aktivasyon fonksiyonuna f verilerek sinir çıktısı a elde edilir.

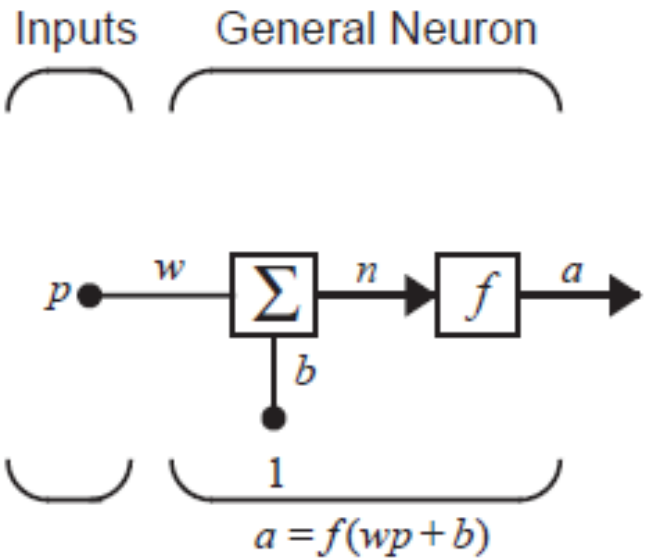

Şekil: Single-Input Neuron

Neuron Output

- Neuron çıktısı

$$a = f(wp + b)$$

Tek-Girişli Sinir
Single-Input Neuron

Single-Input Neuron

- Girdi $p \in \mathbb{R}$, bir ağırlık $w \in \mathbb{R}$ ile çarpılarak wp formatına dönüştürülür.
- Başka bir girdi 1, *bias* b ile çarpılarak bir toplayıcıya verilir.
- Bu toplam n bir aktivasyon fonksiyonuna f verilerek sinir çıktısı a elde edilir.

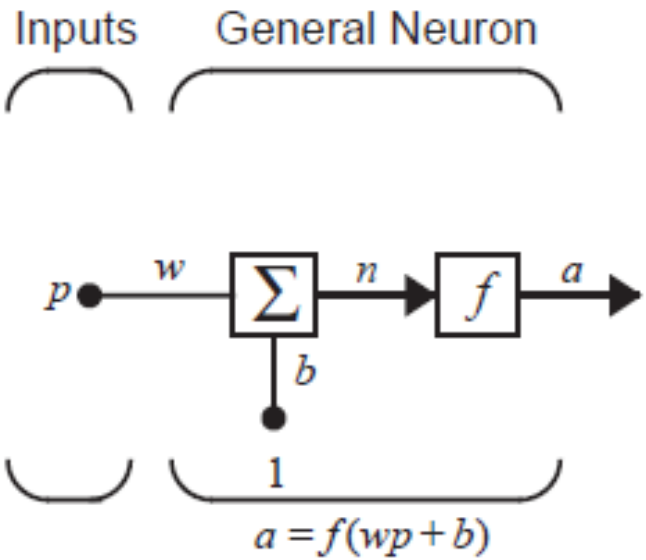

Şekil: Single-Input Neuron

Neuron Output

- $w = 3, p = 2, b = -1.5$
- $a = f(3 \times 2 - 1.5) = f(4.5)$
- Gerçek sonuç aktivasyon fonksiyonuna f bağlı olarak değişiklik gösterecektir.

Tek-Girişli Sinir
Single-Input Neuron

Single-Input Neuron

- Girdi $p \in \mathbb{R}$, bir ağırlık $w \in \mathbb{R}$ ile çarpılarak wp formatına dönüştürülür.
- Başka bir girdi 1, *bias* b ile çarpılarak bir toplayıcıya verilir.
- Bu toplam n bir aktivasyon fonksiyonuna f verilerek sinir çıktısı a elde edilir.

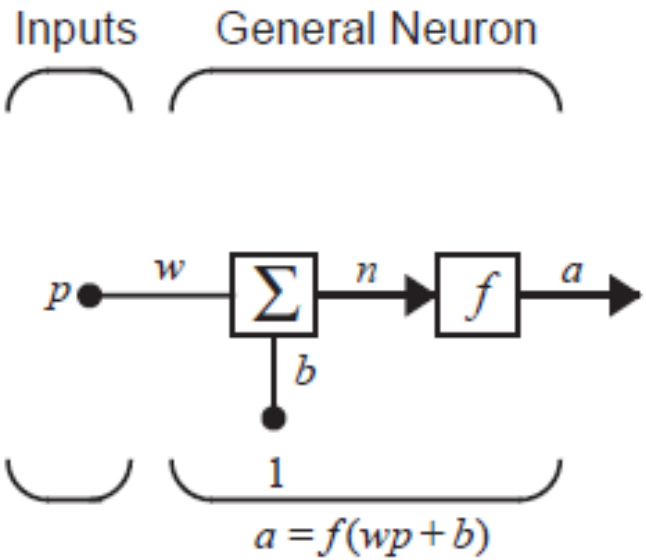

Şekil: Single-Input Neuron

Neuron Output

- Gerçek sonuç aktivasyon fonksiyonuna f bağlı olarak değişiklik gösterecektir.
- w ve b parametreleri öğrenme kuralları uygulanarak bulunacaktır

Aktivasyon Fonksiyonları I
Activation Functions

Hard Limit

- Fonksyion parametresinin belirli bir değerden az olması durumunda 0, diğer durumlarda 1 olacaktır.

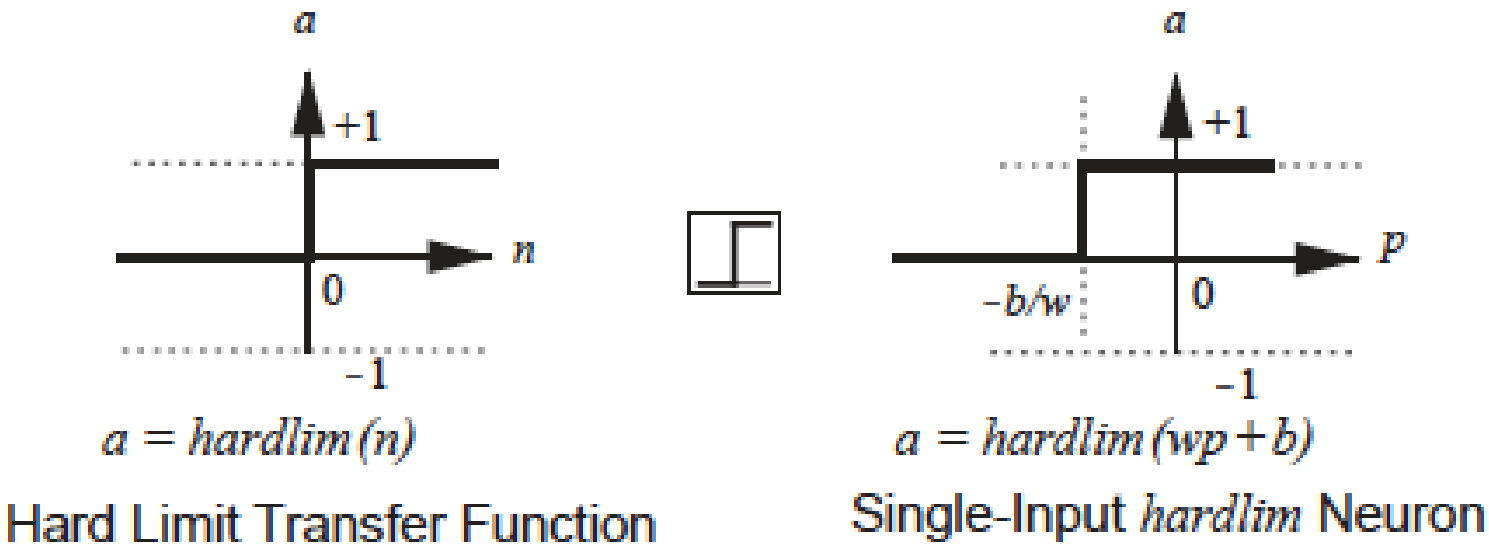

Şekil: Hard Limit Aktivasyon Fonksiyonu

Aktivasyon Fonksiyonları II
Activation Functions

Doğrusal (linear)

- Çıktı değeri, girdi değeri olan fonksiyondur.

$$a = n$$

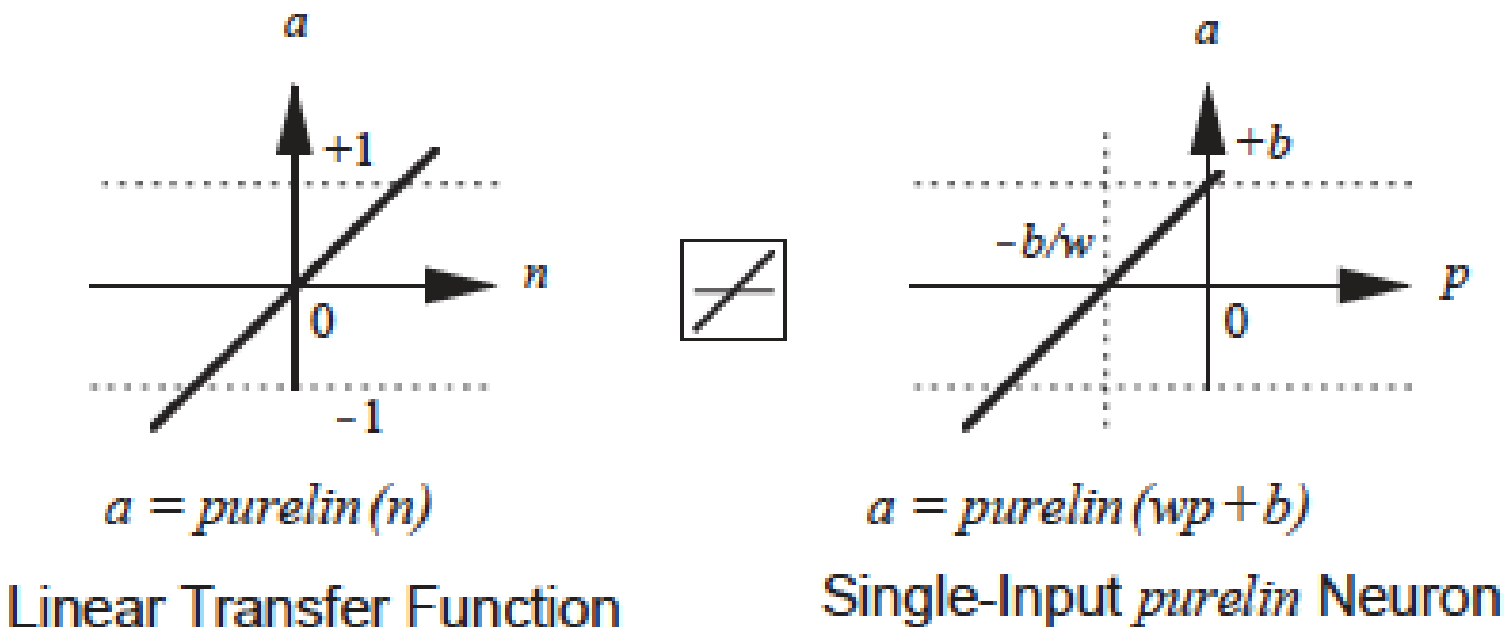

Şekil: Doğrusal Aktivasyon Fonksiyonu

Aktivasyon Fonksiyonları III
Activation Functions

Sigmoid

- Çıktı değeri [0, 1] aralığındadır. $\frac{1}{1+e^{-n}}$

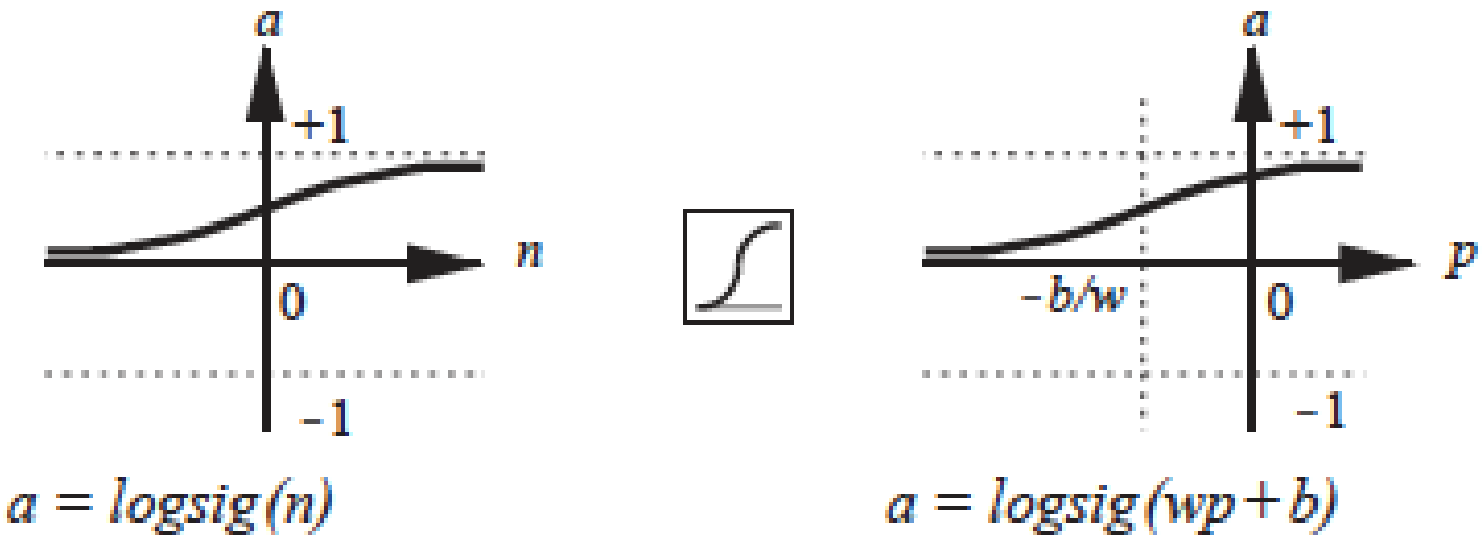

Şekil: Sigmoid Aktivasyon Fonksiyonu

Aktivasyon Fonksiyonları IV
Activation Functions

Diğer Aktivasyon Fonksiyonları

- Exponential Linear Unit (ELU)

$$f(x) = \begin{cases} \alpha(e^x - 1) & for\, x < 0 \\ x & for\, x \geq 0 \end{cases} \tag{1}$$

- Rectified Linear Unit (ReLU)

$$f(x) = \begin{cases} 0 & for\, x < 0 \\ x & for\, x \geq 0 \end{cases} \tag{2}$$

- TanH

$$f(x) = tanh(x) = \frac{2}{1 + e^{-2x}} - 1 \tag{3}$$

- Softplus

$$f(x) = log_e(1 + e^x) \tag{4}$$

- Diğerleri için: `https://keras.io/activations/`

Sinir Ağı ile Sınıflandırma

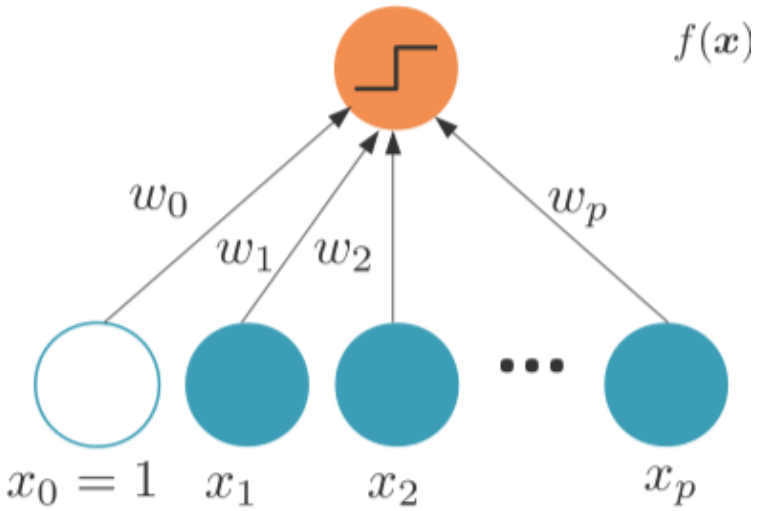

$$h(\mathbf{x}) = f\left(w_0 + \sum_{i=1}^{p} w_i x_i\right) = f(\mathbf{w}^T\mathbf{x}) \quad (5)$$

Lab

Lab-1

Çok Sınıflı Sınıflandırma
Multiclass classifcation

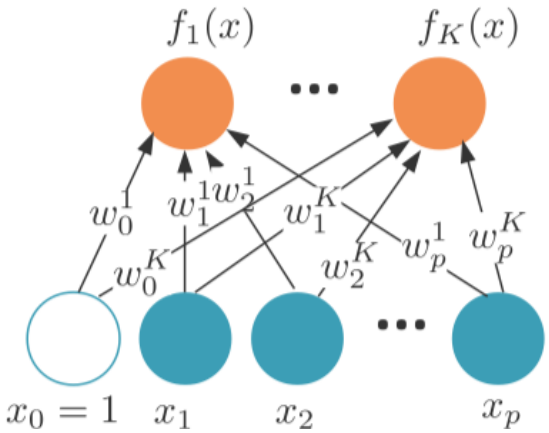

- Modelin sınıf ataması C_k

$$f_k(\mathbf{x}) = \max_{l \in \{1,\cdots,K\}} f_l(\mathbf{x})$$

- Sınıf etiket olasılıkları bulunması için **softmax** kullanılır.

$$f_k(\mathbf{x}) = \frac{e^{o_k}}{\sum_{l=1}^{K} e^{o_l}} \tag{6}$$

$$o_k = \mathbf{w}^{(k)} \cdot \mathbf{x} \tag{7}$$

- Herhangibir sınıfa ait olan değer diğerlerinden yüksek ise, bu sınıfın softmax değeri 1'e yakınlaşacaktır.

```
>>> softmax([1,2])
[0.26894142,      0.73105858])
>>> softmax([10,20])
[0.0000453978687, 0.999954602])
```

```
>>> std_norm([1,2])
[0.3333333333333333, 0.6666666666666666]
>>> std_norm([10,20])
[0.3333333333333333, 0.6666666666666666]
```

Sinir Ağı Öğrenimi
Sinir Ağı Learning

Genel Güncelleme Kuralı

$$\Delta w_j = -\eta \frac{\partial Error\left(f(\mathbf{x}^{(i)}, y_i)\right)}{\partial w_j} \tag{8}$$

- Her bir eğitim örneğinden sonra, her bir ağırlık:

$$w_j^{(t+1)} = w_j^{(t)} + \Delta w_j^{(t)}$$

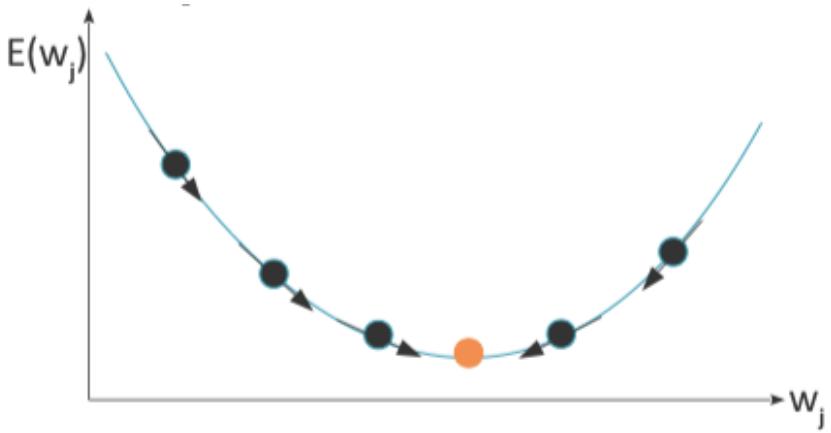

Sinir Ağı Öğrenimi: Sınıflandırma

- **Sigmoid** çıktı:

$$f(\mathbf{x}) = \sigma(\mathbf{w}^T\mathbf{x}) \qquad \sigma(u) = \frac{1}{1+exp(-u)}$$

- Kayıp: **Cross-entropy error**

$$\ell\left(f(\mathbf{x}^{(i)}), y^{(i)}\right) = -y^{(i)} \log f(\mathbf{x}^{(i)}) - (1-y^{(i)}) \log\left(1 - f(\mathbf{x}^{(i)})\right) \quad (9)$$

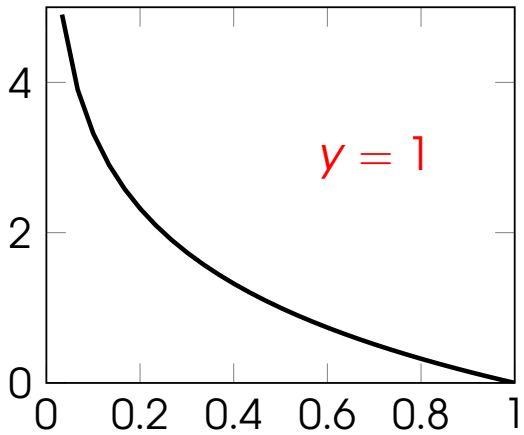

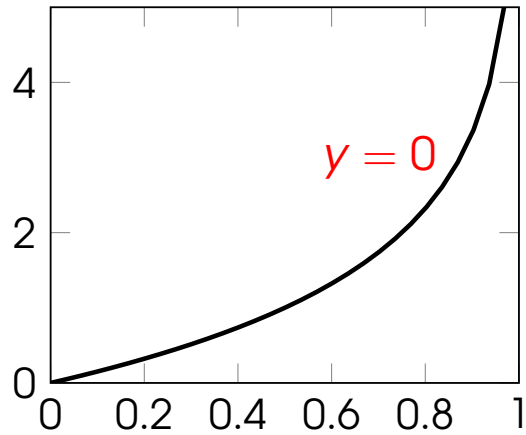

- İkili sınıflandırma için güncelleme kuralı

$$\Delta w_j = -\eta \frac{\partial Error\left(f(\mathbf{x}^{(i)}), y^{(i)}\right)}{\partial w_j} \Rightarrow \Delta w_j = \eta\left(y^{(i)} - f(\mathbf{x}^{(i)})\right) x_j^i \quad (10)$$

Sinir Ağı Öğrenimi: Sınıflandırma

- Güncelleme kuralı

$$\Delta w_j \leftarrow \eta \left(y^{(i)} - f(\mathbf{x}^{(i)}) \right) x_j^{(i)}$$

Update = Learning Rate $\times$ (Actual - Predicted) $\times$ Input

- Her bir eğitim örneği, her bir ağırlık için:

$$w_j^{(t+1)} = w_j^{(t)} + \Delta w_i^{(t)}$$

Lab

Lab-2

Çok Girişli Nöron
Multiple-Input Neuron

Multiple-Input Neuron

- R adet girdisi olan nöron
- Herbir girdi değeri $p_1, \cdots p_R$, bir ağırlık değeri $w_1, \cdots w_R$ ile çarpılmaktadır.

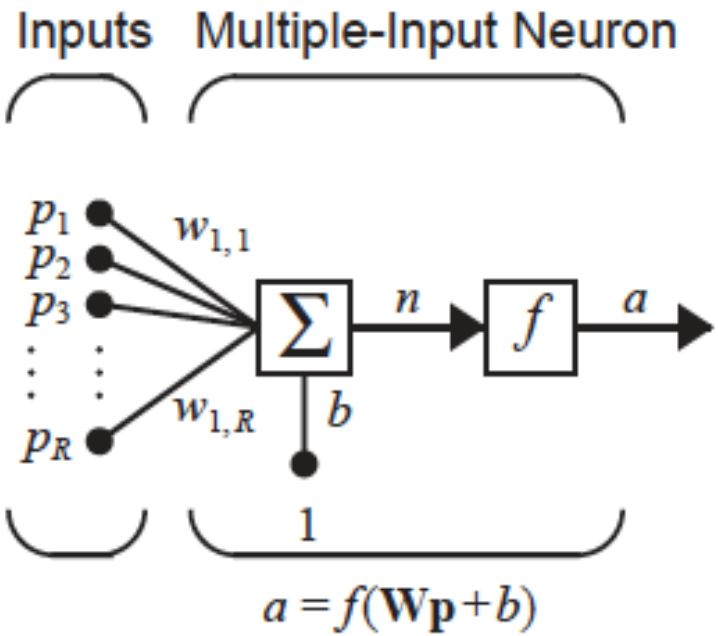

Ağırlık Matrisi (Weight Matrix)

- $n = \mathbf{W}\mathbf{x} + b$
- Single neuron: ağırlık matrisi tek satırdan oluşur. Vektör
- $\mathbf{W} \in \mathbb{R}^p$
- $a = f(\mathbf{W}\mathbf{x} + b)$

Şekil: Multiple-Input Neuron

İçindekiler

Yapay Sinir Ağı Katmanları

Katman (Layer)

- Tek katmanlı S adet sinir hücresi içeren ağ modeli
- Ağırlık matrisi $\mathbf{W} \in \mathbb{R}^{S \times R}$

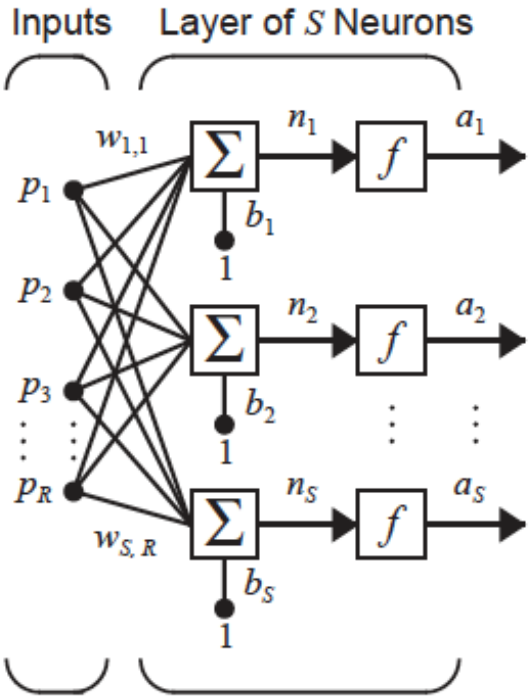

Şekil: Tek katmanlı sinir ağı (single layer neural network)

- $\mathbf{a} = f(\mathbf{W}\mathbf{x} + \mathbf{b})$
- Ağırlık Matrisi

$$\begin{bmatrix} w_{11} & w_{12} & \cdots & w_{1R} \\ w_{21} & w_{22} & \cdots & w_{2R} \\ & \cdots\cdots & & \\ w_{S1} & w_{S2} & \cdots & w_{SR} \end{bmatrix}$$

Multiple Layers of Neurons I

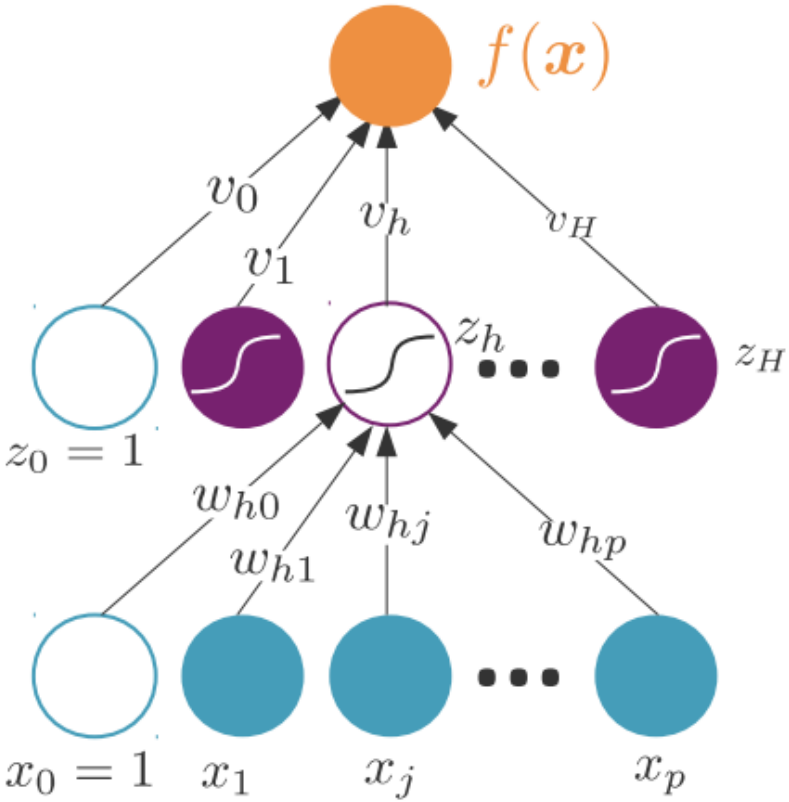

- hidden unit h:

$$z_h = \frac{1}{1 + e^{-\mathbf{w}_h^T \mathbf{x}}}$$

- Ağın çıktı değeri

$$f(\mathbf{x}) = \mathbf{v}^T \mathbf{z}$$

$$= v_0 + \sum_{h=1}^{H} \frac{V_h}{1 + e^{-\mathbf{w}_h^T \mathbf{x}}}$$

Multiple Layers of Neurons II

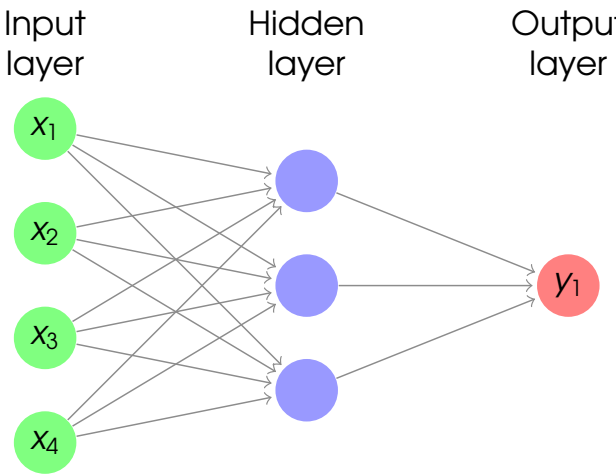

- İlk gizli katmanda bulunan ilk gizli birim (the first hidden unit in the first hidden layer)

$$z_1^{[1]} = \mathbf{W}_1^{[1]^T}\mathbf{x} + b_1^{[1]} \; ve \; a_1^{[1]} = g(z_1^{[1]})$$

- **W**:ağırlık matrisi, $\mathbf{W}_1$: ağırlık matrisinin ilk satırı

- $\mathbf{W}_1^{[1]} \in \mathbb{R}^3$ ve $b_1^{[1]} \in \mathbb{R}$
- Birinci gizli katmanda bulunan ikinci ve üçüncü gizli birimler

$$z_2^{[1]} = \mathbf{W}_2^{[1]^T}\mathbf{x} + b_2^{[1]} \; ve \; a_2^{[1]} = g(z_2^{[1]})$$

$$z_3^{[1]} = \mathbf{W}_3^{[1]^T}\mathbf{x} + b_3^{[1]} \; ve \; a_3^{[1]} = g(z_3^{[1]})$$

- Çıktı katmanı

$$z_1^{[2]} = \mathbf{W}_1^{[2]^T}\mathbf{a}^{[1]} + b_1^{[2]} \; ve \; a_1^{[2]} = g(z_1^{[2]})$$

- $\mathbf{a}^{[1]} = \left[a_1^{[1]} a_2^{[1]} a_3^{[1]}\right]$

Lab

Lab-3

İçindekiler

Derin Öğrenme
Deep Learning

Derin Öğrenme

- Katman sayısının fazla olduğu, çok katmanlı sinir ağı modeli
- Oldukça karmaşık ağ oluşturulabilen parametrik bir model
- Ağırlıklar gradient descent ile öğrenilmektedir.
  - Lokal minimum problemi
- Her bir katman, verinin yeni bir gösterimini (new representation) öğrenmektedir.
  - representation learning

Derin Öğrenme Tipleri

(Derin) sinir ağlarının türleri

- Deep feed-forward (= multilayer perceptrons)
- Unsupervised networks
  - autoencoders / variational autoencoders (VAE) — learn a new representation of the data
  - deep belief networks (DBNs)
  - generative adversarial networks (GANs)
- Convolutional neural networks (CNNs)
  - image/audio modeling
- Recurrent Neural Networks (RNNs)
  - nodes are fed information from the previous layer and also from themselves
  - long short-term memory networks (LSTM) for sequence modeling.

Autoencoders I

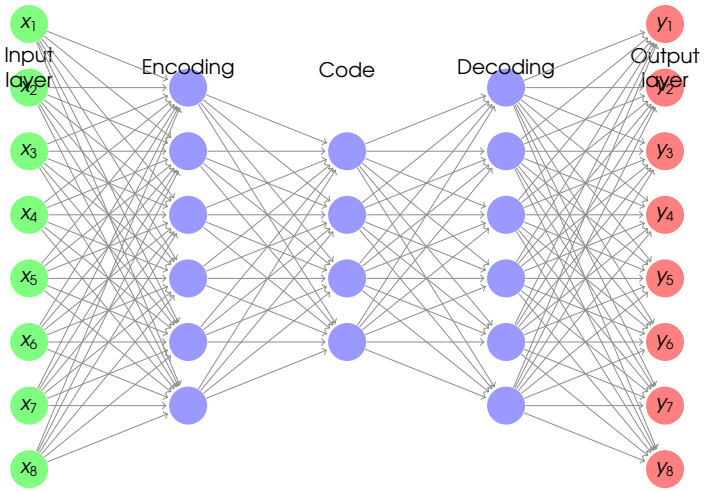

- Hidden layers: Compact representation of input
- $h(\mathbf{x}) \approx \mathbf{x}$
- Reconstruction error: $\ell(\mathbf{x}, \hat{\mathbf{x}}) = ||\mathbf{x} - \hat{\mathbf{x}}||^2$

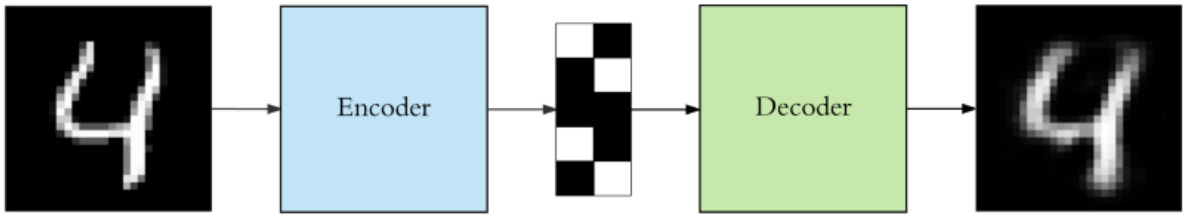

Autoencoders II

Autoencoders Algorithm

- Data-specific Compression: Benzer veriyi sıkıştırmak için uygundur.
- Lossy: Giriş ile tam olarak aynı olmayacak, yakın ancak bozulmuş bir temsil (representation) olacaktır.
- Unsupervised: Veri kümesinden aynı veriyi üretmektedir. *self-supervised*

Autoencoders III

Denoising Autoencoders

- Amaç: Intelligent representation of the data
- Gürültü içeren veriden gürültünün temizlenmesi

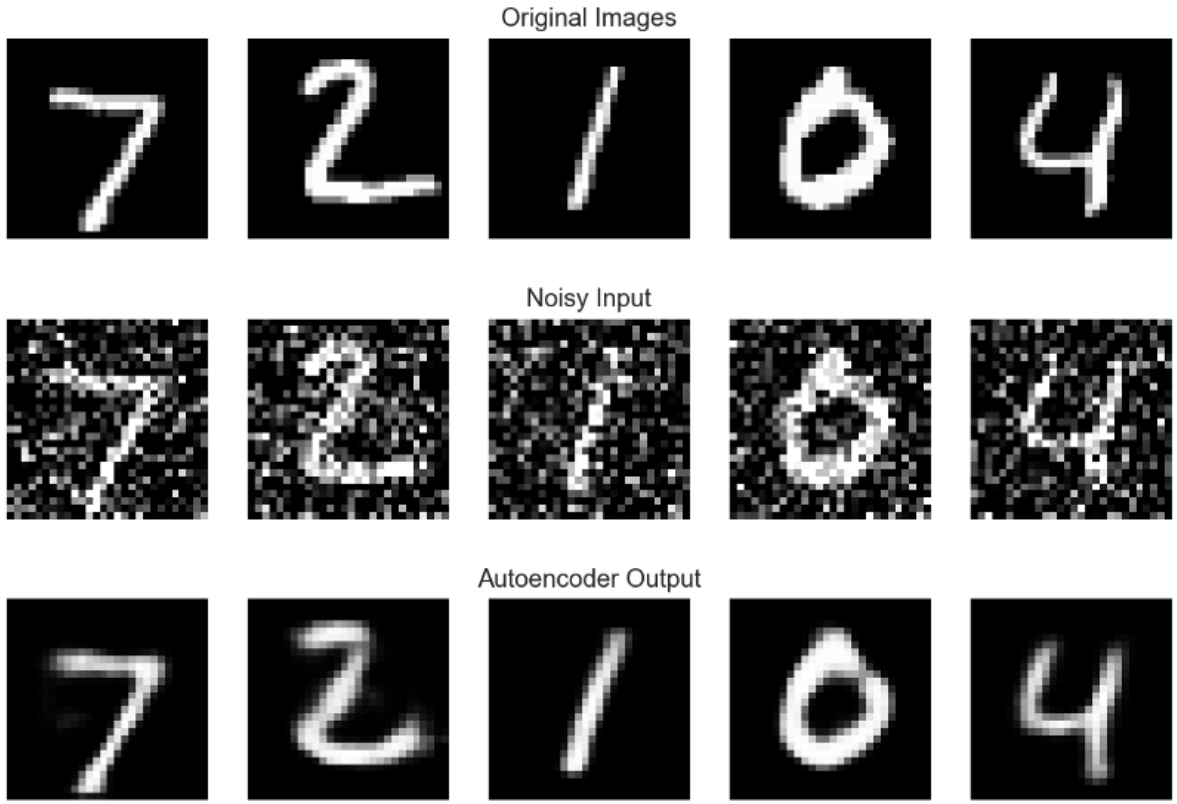

Autoencoders IV

Sparse Autoencoders

- Regularization: Regularize the autoencoder by using a sparsity constraint
- Only a fraction of the nodes would have nonzero values: called active nodes

Lab

Lab-4