

# Hafta 14 - Mahremiyet Korumalı Makine Öğrenmesi

## **BGM 565 - Siber Güvenlik için Makine Öğrenme Yöntemleri**

Bilgi Güvenliği Mühendisliği

Yüksek Lisans Programı

**Dr. Ferhat Özgür Çatak**

ozgur.catak@tubitak.gov.tr

İstanbul Şehir Üniversitesi

2018 - Bahar

# İçindekiler

- 1 Mahremiyet
  - Giriş
  - Mahremiyet Korumalı Makine Öğrenmesi
  - Güvenli Çok Partili Hesaplama
  - Cryptographic privacy preservation

- 2 Uygulamalar
  - Perturbation and Reconstruction
  - Homomorphic Encryption
  - Privacy Preserving SVM
  - Homomorphic Encryption - Privacy Preserving SVM
  - Logistic Regression Encrypted Model

# İçindekiler

- 1 Mahremiyet
  - Giriş
  - Mahremiyet Korumalı Makine Öğrenmesi
  - Güvenli Çok Partili Hesaplama
  - Cryptographic privacy preservation

- 2 Uygulamalar
  - Perturbation and Reconstruction
  - Homomorphic Encryption
  - Privacy Preserving SVM
  - Homomorphic Encryption - Privacy Preserving SVM
  - Logistic Regression Encrypted Model

# Mahremiyet Nedir? I

Privacy

## Mahremiyet

- ▶ Makine öğrenmesi, çeşitli kaynaklardan toplanan veri kümeleri kullanarak kullanıcı davranışları hakkında bilgi vermektedir.
- ▶ Bu yöntemler kullanılarak kişiler hakkında mahrem bilgilere ulaşmak mümkün olabilmektedir.
- ▶ Biyoenformatik, anayurt güvenliği, finans kayıtları

# Mahremiyet Nedir? II

## Privacy

### Sweeney, 2002

- ▶ 2002 yılında Group Insurance Commission (GIC) tarafından yayınlanan **anonimleştirilmiş bir veri kümesi** ve seçmen kayıt listesi kullanılarak Massachusetts valisinin sağlık kayıtları ortaya çıkarıldı.

Voter registration list for Cambridge, Massachusetts							
Name	Address	Date registered	Party affiliation	...	Zip	Birth date	Gender

Medical data in GIC							
Ethnicity	Visit date	Diagnosis	Medication	...	Zip	Birth date	Gender

# Mahremiyet Korumalı Makine Öğrenmesi I

## Mahremiyet Korumalı Makine Öğrenmesi

- ▶ **Amaç:** **Veri kümesini** veya **modeli** yetkisiz kişilerin erişiminden korumak.
- ▶ **Yöntemler**
  - ▶ horizontal or vertical data distribution
  - ▶ data modification methods

	$f_1$	...	$f_d$
$S_1$			
...			
$S_n$			

# Mahremiyet Korumalı Makine Öğrenmesi II

## Partition

- ▶ Veri kümesinin yatay veya dikey olarak parçalanması
- ▶ **Yatay parçalama:** örneklerin parçalanması
- ▶ **Dikey parçalama:** Niteliklerin parçalanması

# Mahremiyet Korumalı Makine Öğrenmesi III

## Data Modification

- ▶ **Perturbation:**
- ▶ **Blocking:** Bir niteliğin *NaN* ile değiştirilmesi
- ▶ **Birleştirme (Aggregation):** Bir niteliği bir dağılım ile değiştirme
- ▶ **Swapping:** Örnekler arasında bilgilerin yerinin değiştirilmesi



# Güvenli Çok Partili Hesaplama I


## Secure Multi Party Computation

### Multi-Parti Computation

- ▶ Genellikle kriptografik protokoller kullanılmaktadır.
- ▶ Diğer çalışmalar randomization/perturbation
- ▶ Dağıtık hesaplama (Distributed computation)
  - ▶ Veri kümesi farklı düğümler arasında dağıtılır.
  - ▶ Cooperative computations on private data

# Güvenli Çok Partili Hesaplama II

## Secure Multi Party Computation



### Örnek Senaryo

- ▶ **Alice**: Hacker profiles
- ▶ **Bob**: Sunucularına saldırı yapılmış olsun.
- ▶ **Bob** saldırı imzasını kullanarak **Alice**'in veritabanını kullanarak saldırganı tespit etmek istesin.
- ▶ Bunu yaparken **Alice**'den imza bilgisini gizlemek istiyor.
- ▶ Alice saldırganın mahrem bilgisini gizleyerek sadece ID bilgisini paylaşacak.


## MPC

- 
- Figure 1 illustrates the proposed algorithm. (a) Initial state: Two groups, Group A and Group B, are shown. Group A has features  $f_1, \dots, f_k$  and samples  $S_1, \dots, S_n$ . Group B has features  $f_{k+1}, \dots, f_d$  and samples  $S_1, \dots, S_n$ . (b) State after the first iteration: Group A's grid is empty. Group B's grid has the first row highlighted in pink and contains features  $f_1, \dots, f_d$  and samples  $S_{k+1}, \dots, S_n$ . Arrows indicate the movement of samples from Group A to Group B.

# Perturbation and Reconstruction

## Perturbation

- ▶ Randomization kullanılarak hassas bilginin korunması
- ▶ Orjinal veri kümesi:  $\mathcal{X} \in \mathbb{R}^{m \times n}$
- ▶ Perturbation matrix:  $\mathcal{R} \in \mathbb{R}^{m \times n}$
- ▶ Distorted data set:  $\mathcal{Y} = \mathcal{X} + \mathcal{R}$
- ▶ Reconstruction:  $\mathcal{X} = \mathcal{Y} - \mathcal{R}$



# Homomorphic Encryption I

## Homomorphic Encryption

- ▶ Şifreli metinler üzerinde hesaplamaya izin veren bir şifreleme şeklidir.
- ▶ Sonuç şifrelenmiştir.
- ▶ Şifre çözüldüğünde, açık metin hesaplama ile aynı sonucu vermektedir.
- ▶ Homomorfik şifrelemenin amacı, şifrelenmiş veriler üzerinde hesaplamaya izin vermektir.
- ▶ Bulut bilişim için oldukça uygun bir hesaplama yöntemidir.

# Homomorphic Encryption II

## Partially homomorphic cryptosystems

- ▶ Kısmi Homomorfik Şifreleme (PHE) şemaları, belirli matematiksel işlemlerin şifreli veriler üzerinden hesaplanmasını sağlar.
- ▶ **Paillier cryptosystem** (additive homomorphic schemes):
  - ▶  $Enc(m_1) + Enc(m_2) = Enc(m_1 + m_2)$
  - ▶  $a \times m_1 = Dec(Enc(m_1)^a)$

## Floating Point Numbers

- ▶ Paillier sadece tamsayılarla çalışabilmektedir.
- ▶ Veri kümesinden dönüşüm yapılmalıdır.  $\mathbb{R}^{m \times n} \rightarrow \mathbb{Z}^{m \times n}$
- ▶ Gerçekleştirimlerde bir exponent ( $K : 2^K$ ) çarpılarak rounding yapılır.
- ▶ Bilgi kaybı

# Lab-1

# İçindekiler

1

## Mahremiyet

- Giriş
- Mahremiyet Korumalı Makine Öğrenmesi
- Güvenli Çok Partili Hesaplama
- Cryptographic privacy preservation

2

## Uygulamalar

- Perturbation and Reconstruction
- Homomorphic Encryption
- Privacy Preserving SVM
- Homomorphic Encryption - Privacy Preserving SVM
- Logistic Regression Encrypted Model



# Privacy Preserving SVM I

## SVM



$$\min_{\alpha} \frac{1}{2} \alpha Q \alpha - \epsilon \alpha$$

$$s.t. 0 \leq \alpha_i \leq v$$

$$\sum_i d_i \alpha_i = 0 \quad i = 0, \dots, m$$

►  $X \in \mathbb{R}^{m \times n} \quad Q \in \mathbb{R}^{m \times m}$

►  $Q_{ij} = K(\mathbf{x}_i, \mathbf{x}_j)$

► **Linear:**  $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i \cdot \mathbf{x}_j$




Figure 1: The separating hyperplane that maximizes the margin. ('o' is a positive data point, i.e.  $f('o') > 0$ , and '+' is a negative data point, i.e.  $f('+') < 0$ .)

# Privacy Preserving SVM II

## Kernel Matrix (Gram Matrix)

$K = K(\mathbf{x}_i, \mathbf{x}_j)$ , for  $i, j = 1, \dots, m$

$$K = \begin{bmatrix} K(\mathbf{x}_1, \mathbf{x}_1) & K(\mathbf{x}_1, \mathbf{x}_2) & K(\mathbf{x}_1, \mathbf{x}_3) & \dots & K(\mathbf{x}_1, \mathbf{x}_m) \\ K(\mathbf{x}_2, \mathbf{x}_1) & K(\mathbf{x}_2, \mathbf{x}_2) & K(\mathbf{x}_2, \mathbf{x}_3) & \dots & K(\mathbf{x}_2, \mathbf{x}_m) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ K(\mathbf{x}_m, \mathbf{x}_1) & K(\mathbf{x}_m, \mathbf{x}_2) & K(\mathbf{x}_m, \mathbf{x}_3) & \dots & K(\mathbf{x}_m, \mathbf{x}_m) \end{bmatrix}$$

# Privacy Preserving SVM III

Yu, Hwanjo, Jaideep Vaidya, and Xiaoqian Jiang. "Privacy-preserving svm classification on vertically partitioned data." *Pacific-Asia Conference on Knowledge Discovery and Data Mining*. Springer, Berlin, Heidelberg, 2006.




Fig. 3. Vertically partitioned matrix  $\mathcal{A}$

**Lemma 1.** Suppose the  $m \times n$  data matrix  $\mathcal{A}$  is vertically partitioned into  $\mathcal{A}^1$  and  $\mathcal{A}^2$  as Figure 3 illustrates. Let  $\mathcal{K}^1$  and  $\mathcal{K}^2$  be the  $m \times m$  gram matrices of matrices  $\mathcal{A}^1$  and  $\mathcal{A}^2$  respectively. That is,  $\mathcal{K}^1 = \mathcal{A}^1 \mathcal{A}^{1'}$  and  $\mathcal{K}^2 = \mathcal{A}^2 \mathcal{A}^{2'}$ . Then,  $\mathcal{K}$ , the gram matrix of  $\mathcal{A}$ , can be computed as follows:

$$\mathcal{K} = \mathcal{K}^1 + \mathcal{K}^2 = \mathcal{A}^1 \mathcal{A}^{1'} + \mathcal{A}^2 \mathcal{A}^{2'} \quad (5)$$

*Proof.* An  $(i, j)^{th}$  element of  $\mathcal{K}$  is  $x_i \cdot x_j$ , where  $x_i$  and  $x_j$  are  $i^{th}$  and  $j^{th}$  data vectors in  $\mathcal{A}$ . Let  $x_i^1$  and  $x_i^2$  be vertically partitioned vectors of  $x_i$ , which are the parts from  $\mathcal{A}^1$  and  $\mathcal{A}^2$  respectively. Then,

$$x_i \cdot x_j = x_i^1 \cdot x_j^1 + x_i^2 \cdot x_j^2 \quad (6)$$

From Eq.(6), each element in  $\mathcal{K}$  is equal to the sum of the elements in  $\mathcal{K}^1$  and  $\mathcal{K}^2$ . Thus  $\mathcal{K} = \mathcal{K}^1 + \mathcal{K}^2$ .



# Lab-2

# Homomorphic Encryption - Privacy Preserving SVM

Zhan, Justin, L. Chang, and Stan Matwin.  
 "Privacy-preserving support vector machines  
 learning." *Proceedings of the 2005 International  
 Conference on Electronic Business (ICEB'05)*. 2005.

**Protocol 1** *INPUT:  $P_1$ 's input is a vector  $\vec{x}_1 = \{x_{11}, x_{12}, \dots, x_{1m}\}$ , and  $P_2$ 's input is a vector  $\vec{x}_2 = \{x_{21}, x_{22}, \dots, x_{2m}\}$ . The elements in the input vectors are taken from the real number domain.*

1.  $P_1$  performs the following operations:


- (a) She computes  $e(x_{1i} + r_i)$ s ( $i \in [1, m]$ ) and sends them to  $P_2$ .  $r_i$ , known only by  $P_1$ , is a random number in real domain.
- (b) She computes  $e(-r_i)$ s ( $i \in [1, m]$ ) and sends them to  $P_2$ .

2.  $P_2$  performs the following operations:

- (a) He computes  $t_1 = e(x_{11} + r_1)^{x_{21}} = e(x_{11} \cdot x_{21} + r_1 x_{21})$ ,  $t_2 = e(x_{12} + r_2)^{x_{22}} = e(x_{12} \cdot x_{22} + r_2 x_{22})$ ,  $\dots$ ,  $t_m = e(x_{1m} + r_m)^{x_{2m}} = e(x_{1m} \cdot x_{2m} + r_m x_{2m})$ .
- (b) He computes  $t_1 \times t_2 \times \dots \times t_m = e(x_{11} \cdot x_{21} + x_{12} \cdot x_{22} + \dots + x_{1m} \cdot x_{2m} + r_1 x_{21} + r_2 x_{22} + \dots + r_m x_{2m}) = e(\vec{x}_1 \cdot \vec{x}_2 + \sum_{i=1}^m r_i x_{2i})$ .
- (c) He computes  $e(-r_i)^{x_{2i}} = e(-r_i x_{2i})$  for  $i \in [1, m]$ .
- (d) He computes  $e(\vec{x}_1 \cdot \vec{x}_2 + \sum_{i=1}^m r_i x_{2i}) \times e(-r_1 x_{21}) \times e(-r_2 x_{22}) \times \dots \times e(-r_m x_{2m}) = e(\vec{x}_1 \cdot \vec{x}_2)$ .

# Lab-3

# Logistic Regression Encrypted Model I



- ▶ Alice bir sınıflandırıcı eğitmektedir (spam classifier)
- ▶ Oluşan bu modeli Bob'un kişisel e-postalarına uygulamak istemektedir.
  - ▶ Alice eğitim kümesini ve modeli paylaşmamaktadır.
  - ▶ Bob e-postalarını paylaşmadan ve şifreli modeli kullanarak sınıf etiketlerini öğrenmektedir.



# Logistic Regression Encrypted Model II

## Adımlar

- ▶ Alice, spam e-posta veri kümesini kullanarak logistic regression ile bir model oluşturur.
- ▶ Alice, Paillier'i kullanarak public/private key pair oluşturur.
- ▶ Model public key ile şifrelenmiştir.
- ▶ Public key ve model Bob'a gönderilir.
- ▶ Bob, her bir e-posta için şifreli modeli kullanarak şifreli skorları elde eder.
- ▶ Bob şifreli skorları Alice'e gönderir.
- ▶ Alice şifreli skor değerleri açarak spam olup olmadığı bilgisini Bob'a geri gönderir.

# Lab-4